学习日志

姓名: 辛昊洋 学号: 1813090 日期: 6.25

学习内容安排: (以 6.15 为例)

上午:

MapReduce 工作原理

下午:

MapReduce 的类型与格式

学习反馈:

已掌握知识: 作业流程:

- 1.在客户端启动一个作业。
- 2.向 JobTracker 请求一个 Job ID。

3.将运行作业所需要的资源文件复制到 HDFS 上,包括 MapReduce 程序打包的 JAR 文件、配置文件和客户端计算所得的输入划分信息。这些文件都存放在 JobTracker 专门为该作业创建的 文件 夹中。 文件 夹名为该作业的 Job ID。 JAR 文件默认会有 10个副本(mapred.submit.replication属性控制);输入划分信息告诉了 JobTracker 应该为这个作业启动多少个 map 任务等信息。

4.JobTracker 接收到作业后,将其放在一个作业队列里,等待作业调度器对其进行调度(这里是不是很像微机中的进程调度呢,呵呵),当作业调度器根据自己的调度算法调度到该作业时,会根据输入划分信息为每个划分创建一个 map 任务,并将 map 任务分配给 TaskTracker 执行。对于 map 和 reduce 任务,TaskTracker 根据主机核的数量和内存的大小有固定数量的 map 槽和 reduce 槽。这里需要强调的是:map 任务不是随随便便地分配给某个 TaskTracker 的,这里有个概念叫:数据本地化(Data-Local)。意思是:将 map 任务分配给含有该 map 处理的数据块的 TaskTracker 上,同时将程序 JAR 包复制到该 TaskTracker 上来运行,这叫"运算移动,数据不移动"。而分配 reduce 任务时并不考虑数据本地化。

5.TaskTracker 每隔一段时间会给 JobTracker 发送一个心跳,告诉 JobTracker 它依然在运行,同时心跳中还携带着很多的信息,比如当前 map 任务完成的进度等信息。当 JobTracker 收到作业的最后一个任务完成信息时,便把该作业设置成"成功"。当 JobClient 查询状态时,它将得知任务已完成,便显示一条消息给用户。

MapReduce 的类型

Hadoop 的 MapReduce 中, map 函数和 reduce 函数遵循如下格式:

map: (k1,v1) --->list(k2,v2)

combiner: (k2,list(v2)) ---> lsit (k2,v2) reduce: (k2,list(v2)) --->list (k3,v3)

未掌握知识: 代码实操

学习心得:最近的理论性看得比较多,实践不足。初次接触 hadoop,感觉他对大量数据的处理和流处理非常优秀,也比较复杂,需要多加反复的去理解。